

LAPORAN

PRAKTIKUM PEMODELAN STATISTIKA

MODUL 2



Disusun oleh :

Nama : Fidelia Ping
NIM : 245410012
Kelas : Informatika 1

PROGRAM STUDI INFORMATIKA
PROGRAM SARJANA
FAKULTAS TEKNOLOGI INFORMASI
UNIVERSITAS TEKNOLOGI DIGITAL INDONESIA
YOGYAKARTA
2025

MODUL 2

PENGELOLAAN DATA DENGAN R

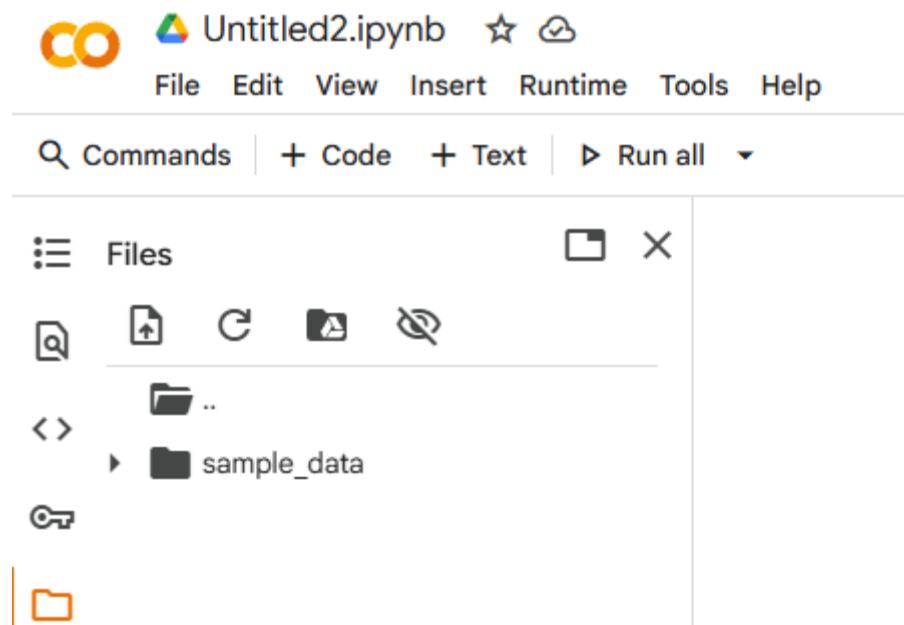
A. PEMBAHASAN PRAKTIK

a. Praktik impor file dari upload lokal di google colab

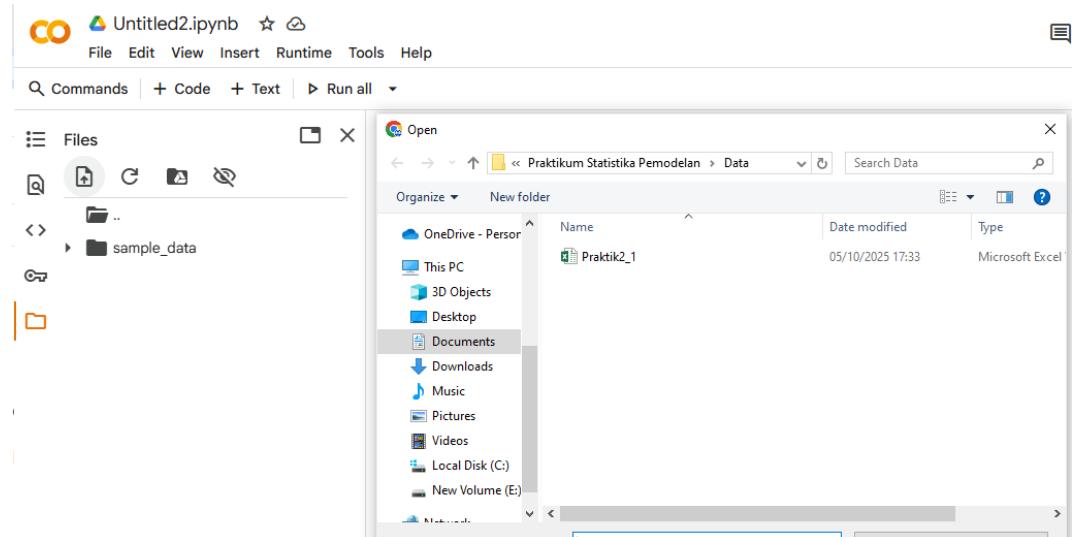
- Buat file dalam Excel dari data dibawah, simpan di komputer lokal, misal diberi nama Praktik2_1

Nama	IPK
Andi	3.6
Budi	3.4
Cici	3.3
Dodi	2.9
Ina	2.8
Rudi	3.0
Rini	2.4
Yani	1.9
Yuli	2.5
Val	2.8

- Masuk di Google Colab dengan login di akun anda
- Untuk mengunggah file Praktik2_1.xlsx, klik ikon folder di sidebar kiri Colab (panel Files).



- Klik ikon upload (kertas dengan panah ke atas) dan pilih file dari komputer.



- File akan tersimpan sementara di direktori /content.

The screenshot shows the Google Colab interface with the uploaded file 'Praktik2_1.xlsx' listed in the 'Files' sidebar. The file is located in the '/content' directory.

- Untuk mengimpor file excel yang diunggah, sebelumnya copi path file yang akan diimport, gunakan perintah

```
# Praktik Impor File Excel di Google Colab

# 1. Instal dan muat paket readxl
cat("== Menginstal dan Memuat Paket readxl ==\n")
install.packages("readxl")
library(readxl)

# 2. Membaca file Excel
# Menggunakan read_excel() dari paket readxl
cat("\n== Membaca File Excel ==\n")
data <- read_excel("/content/Praktik2_1.xlsx", sheet = 1)
print(data)
```

Pembahasan: Bagian pertama dari kode ini memastikan bahwa R memiliki semua alat yang dibutuhkan untuk membaca file Excel. cat("== Menginstal dan Memuat Paket readxl ==\n") Fungsi cat() digunakan untuk menampilkan output ke konsol. Ini seperti fungsi print(), tetapi seringkali lebih cocok untuk menampilkan pesan yang diformat. Output yang dihasilkan adalah: == Menginstal dan Memuat Paket readxl == install.packages("readxl") Ini adalah perintah penting yang digunakan untuk mengunduh dan memasang paket (package) readxl dari repositori CRAN. Paket readxl adalah pustaka spesifik di R yang dirancang untuk membaca data dari file Microsoft Excel (.xlsx dan .xls). Di Google Colab, perintah ini akan menginstal paket. Pada bagian cat("\n==

Membaca File Excel ===\n") Sama seperti sebelumnya, ini hanya menampilkan pesan informatif ke konsol. Outputnya adalah: === Membaca File Excel === data <read_excel("/content/Praktik2_1.xlsx", sheet = 1) Ini adalah perintah utama untuk mengimpor data. Mari kita pecah: read_excel(): Fungsi ini adalah bagian dari paket readxl yang sudah kita muat. "/content/Praktik2_1.xlsx": Ini adalah jalur (path) file. Di Google Colab, file yang diunggah ke panel "Files" akan disimpan sementara di direktori /content/. Jadi, ini adalah alamat di mana R akan menemukan file. sheet = 1: Parameter ini menentukan lembar kerja (sheet) mana di dalam file Excel yang akan dibaca. Angka 1 berarti R akan membaca lembar kerja pertama. data <- ...: Hasil dari fungsi read_excel() (yaitu, data dari Excel) akan disimpan ke dalam variabel bernama data. Variabel ini sekarang berisi sebuah data frame di R, yang merupakan struktur data berbentuk tabel. print(data) Perintah ini menampilkan isi dari variabel data ke konsol.

Output

```
==== Membaca File Excel ====
# A tibble: 10 × 2
  Nama    IPK
  <chr>   <dbl>
1 Andi     3.6
2 Budi     3.4
3 Cici     3.3
4 Dodi     2.9
5 Ina      2.8
6 Rudi     3.0
7 Rini     2.4
8 Yani     1.9
9 Yuli     2.5
10 Val     2.8
```

Pembahasan: dapat dilihat outputnya menampilkan table dari file excel ke konsol dengan 10 baris dan 2 kolom (Nama dan IPK) telah dibuat. R secara otomatis mengenali tipe data: <chr> untuk karakter (nama) dan <dbl> untuk ganda (angka desimal, IPK).

b. Praktik memeriksa data

```
# 1. Membuat dataset
data <- data.frame(
  id = c(1, 1, 2, 3, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18,
        19, 20, 21, 22, 23, 24, 25, 26, 27, 28),
  umur = c(25, 25, 30, 22, 22, 35, 28, 40, 33, 27, 29, NA, 31, 26, 38, 45, 23,
          29, 34, 36, 41, 27, 30, 32, NA, 28, 39, 24, 31, 50),
  pendapatan = c(5000, 5000, 6000, 4500, 4500, 7000, 5500, 8000, 6200, NA,
                 5100, 4900, 7500, 5200, 6800, 9000, 4700, 5300, 6100, 7200,
                 NA, 5400, 6500, 4800, 5100, 5900, 7800, 4600, 6700, 15000),
  kategori = c("PNS", "PNS", "Swasta", "Wirausaha", "Wirausaha", "PNS",
              "Swasta", "PNS", "Wirausaha", "Swasta", "PNS", "Swasta",
              "PNS", "Wirausaha", "Swasta", "PNS", "Wirausaha", "Swasta",
              "PNS", "Swasta", "Wirausaha", "PNS", "Swasta", "Wirausaha",
              "PNS", "Swasta", "PNS", "Wirausaha", "Swasta", "PNS")
)

# 2. Memeriksa Data

# a. Melihat data secara umum
cat("== a. Melihat Data Secara Umum ==\n")
cat("Semua data:\n")
```

```

print(data)
cat("\nHead (6 baris pertama):\n")
print(head(data))
cat("\nTail (6 baris terakhir):\n")
print(tail(data))

# b. Memeriksa struktur data
cat("\n== b. Memeriksa Struktur Data ==\n")
str(data)

# c. Memeriksa dimensi data
cat("\n== c. Memeriksa Dimensi Data ==\n")
cat("Dimensi (baris, kolom):", dim(data), "\n")
cat("Jumlah baris:", nrow(data), "\n")
cat("Jumlah kolom:", ncol(data), "\n")
cat("Nama kolom:", names(data), "\n")

# d. Ringkasan statistik
cat("\n== d. Ringkasan Statistik ==\n")
summary(data)

# e. Mengecek nilai hilang
cat("\n== e. Mengecek Nilai Hilang ==\n")
cat("Jumlah NA per kolom:\n")
print(colSums(is.na(data)))
cat("Jumlah baris lengkap (tanpa NA):", sum(complete.cases(data)), "\n")

# f. Mengecek duplikat
cat("\n== f. Mengecek Duplikat ==\n")
cat("Jumlah baris duplikat:", sum(duplicated(data)), "\n")
cat("Baris duplikat:\n")
print(data[duplicated(data), ])

# g. Mengecek outlier pada pendapatan
cat("\n== g. Mengecek Outlier ==\n")
Q1 <- quantile(data$pendapatan, 0.25, na.rm = TRUE)
Q3 <- quantile(data$pendapatan, 0.75, na.rm = TRUE)
IQR <- Q3 - Q1
lower_bound <- Q1 - 1.5 * IQR
upper_bound <- Q3 + 1.5 * IQR
cat("Batas bawah (Q1 - 1.5 * IQR):", lower_bound, "\n")
cat("Batas atas (Q3 + 1.5 * IQR):", upper_bound, "\n")
outliers <- data$pendapatan[data$pendapatan < lower_bound |
                                data$pendapatan > upper_bound & !is.na(data$pendapatan)]
cat("Nilai outlier pada pendapatan:", outliers, "\n")

```

Pembahasan: pada praktik ini terdapat 2 bagian utama yang pertama membuat Dataset dan memeriksa kualitas data pada bagian pertama Kode ini dimulai dengan membuat sebuah data frame. Di R, data frame adalah struktur data berbentuk tabel yang paling sering digunakan, mirip seperti spreadsheet. `data <- data.frame(...)`: Perintah ini membuat sebuah data frame baru dan menyimpannya ke dalam variabel bernama `data`. Di dalam `data.frame()` ini untuk mendefinisikan empat kolom: `id`, `umur`,

pendapatan, dan kategori. Setiap kolom dibuat dari sebuah vektor (kumpulan nilai) yang disatukan dengan fungsi c(). Terdapat beberapa nilai NA di kolom umur dan pendapatan. NA (Not Available) adalah cara R untuk merepresentasikan data yang hilang atau tidak ada. Pada bagian ke 2 kode tersebut Setelah data frame dibuat, kode ini menjalankan serangkaian perintah untuk memeriksa kualitas dan karakteristik datanya.

Output

```
==> === a. Melihat Data Secara Umum ===
Semua data:
  id umur pendapatan kategori
1 1 25 5000 PNS
2 1 25 5000 PNS
3 2 30 6000 Swasta
4 3 22 4500 Wirausaha
5 3 22 4500 Wirausaha
6 4 35 7000 PNS
7 5 28 5500 Swasta
8 6 40 8000 PNS
9 7 33 6200 Wirausaha
10 8 27 NA Swasta
11 9 29 5100 PNS
12 10 NA 4900 Swasta
13 11 31 7500 PNS
14 12 26 5200 Wirausaha
15 13 38 6800 Swasta
16 14 45 9000 PNS
17 15 23 4700 Wirausaha
18 16 29 5300 Swasta
19 17 34 6100 PNS
20 18 36 7200 Swasta
21 19 41 NA Wirausaha
22 20 27 5400 PNS
23 21 30 6500 Swasta
24 22 32 4800 Wirausaha
25 23 NA 5100 PNS
26 24 28 5900 Swasta
27 25 39 7800 PNS
28 26 24 4600 Wirausaha
29 27 31 6700 Swasta
30 28 50 15000 PNS

Head (6 baris pertama):
  id umur pendapatan kategori
1 1 25 5000 PNS
2 1 25 5000 PNS
3 2 30 6000 Swasta
4 3 22 4500 Wirausaha
5 3 22 4500 Wirausaha
6 4 35 7000 PNS

Tail (6 baris terakhir):
  id umur pendapatan kategori
25 23 NA 5100 PNS
26 24 28 5900 Swasta
27 25 39 7800 PNS
28 26 24 4600 Wirausaha
29 27 31 6700 Swasta
30 28 50 15000 PNS

==> === b. Memeriksa Struktur Data ===
'data.frame': 30 obs. of 4 variables:
 $ id      : num  1 1 2 3 3 4 5 6 7 8 ...
 $ umur    : num  25 25 30 22 22 35 28 40 33 27 ...
 $ pendapatan: num  5000 5000 6000 4500 4500 7000 5500 8000 6200 NA ...
```

```

    === c. Memeriksa Dimensi Data ===
    ⚡ Dimensi (baris, kolom): 30 4
    Jumlah baris: 30
    Jumlah kolom: 4
    Nama kolom: id umur pendapatan kategori

    === d. Ringkasan Statistik ===
      id          umur      pendapatan      kategori
      Min. : 1.00  Min. :22.00  Min. : 4500  Length:30
      1st Qu.: 6.25  1st Qu.:26.75  1st Qu.: 5000  Class :character
      Median :13.50  Median :30.00  Median : 5700  Mode  :character
      Mean   :13.67  Mean   :31.43  Mean   : 6261
      3rd Qu.:20.75  3rd Qu.:35.25  3rd Qu.: 6850
      Max.   :28.00  Max.   :50.00  Max.   :15000
      NA's    :2       NA's    :2       NA's    :2

    === e. Mengecek Nilai Hilang ===
    Jumlah NA per kolom:
      id          umur      pendapatan      kategori
      0           2           2           0
    Jumlah baris lengkap (tanpa NA): 26

    === f. Mengecek Duplikat ===
    Jumlah baris duplikat: 2
    Baris duplikat:
      id umur pendapatan kategori
      2  1   25      5000     PNS
      5  3   22      4500  Wirausaha

    === g. Mengecek Outlier ===
    Batas bawah (Q1 - 1.5 * IQR): 2225
    Batas atas (Q3 + 1.5 * IQR): 9625
    Nilai outlier pada pendapatan: NA NA 15000

```

Pembahasan:

a. Melihat Data Secara Umum

`cat("== a. Melihat Data Secara Umum ==\n")`: Ini hanya untuk menampilkan pesan di konsol. `print(data)`: Perintah ini menampilkan seluruh data frame di layar. Outputnya adalah tabel lengkap dari 30 baris dan 4 kolom yang dibuat. `print(head(data))` dan `print(tail(data))`: Fungsi ini sangat berguna untuk melihat gambaran cepat data tanpa mencetak semuanya. `head()` menampilkan 6 baris pertama, sedangkan `tail()` menampilkan 6 baris terakhir.

b. Memeriksa Struktur Data

`cat("\n== b. Memeriksa Struktur Data ==\n")`: Pesan lagi. `str(data)`: Fungsi `str()` (singkatan dari `structure`) adalah salah satu alat terbaik untuk memahami data. Outputnya akan menunjukkan: Tipe objeknya ('`data.frame`'). Jumlah observasi (baris) dan variabel (kolom) (30 obs. of 4 variables). Nama setiap kolom dan tipe datanya (misalnya, `int` untuk integer, `num` untuk numerik, `chr` untuk karakter).

c. Memeriksa Dimensi Data

`cat("\n== c. Memeriksa Dimensi Data ==\n")`: Pesan. `dim(data)`: Mengembalikan jumlah baris dan kolom sebagai dua angka. Outputnya adalah 30 4. `nrow(data)`: Mengembalikan jumlah baris, yaitu 30. `ncol(data)`: Mengembalikan jumlah kolom, yaitu 4. `names(data)`: Mengembalikan nama-nama kolom ("id" "umur" "pendapatan" "kategori").

d. Ringkasan Statistik

`summary(data)`: Perintah ini memberikan ringkasan statistik deskriptif untuk setiap kolom. Untuk kolom numerik (id, umur, pendapatan), ia menampilkan nilai minimum, Q1, median, rata-rata, Q3, dan nilai maksimum. Untuk kolom karakter (kategori), ia menampilkan frekuensi dari nilai-nilai unik. Ini membantu untuk melihat sebaran data secara sekilas.

e. Mengecek Nilai Hilang

`print(colSums(is.na(data)))`: Ini adalah cara pintar untuk menghitung NA per kolom. `is.na(data)` membuat sebuah tabel logis (TRUE/FALSE) di mana TRUE menunjukkan adanya NA. `colSums()` menjumlahkan nilai TRUE di setiap kolom (di R, TRUE dihitung sebagai 1 dan FALSE sebagai 0). Outputnya akan menunjukkan: id = 0, umur = 2, pendapatan = 2, dan kategori = 0. Ini berarti ada dua nilai hilang di kolom umur dan dua di kolom pendapatan. `sum(complete.cases(data))`: Menghitung berapa banyak baris yang tidak memiliki NA sama sekali. Outputnya adalah 26, karena 4 baris mengandung NA (2 di umur dan 2 di pendapatan).

f. Mengecek Duplikat

sum(duplicated(data)): Menghitung jumlah baris duplikat. duplicated() akan mengembalikan TRUE untuk baris yang merupakan salinan dari baris yang sudah ada. Outputnya adalah 2. print(data[duplicated(data),]): Menampilkan baris-baris yang duplikat. Outputnya akan menunjukkan baris kedua (id 1) dan baris kelima (id 3), mengonfirmasi bahwa mereka adalah duplikat.

g. Mengecek Outlier

Kode ini menggunakan metode Interquartile Range (IQR) untuk mendeteksi outlier pada kolom pendapatan. Q1 <- quantile(data\$pendapatan, 0.25, na.rm = TRUE): Menghitung kuartil pertama (Q1), yang merupakan 25% nilai terendah. na.rm = TRUE memastikan nilai NA diabaikan dalam perhitungan. Q3 <- quantile(data\$pendapatan, 0.75, na.rm = TRUE): Menghitung kuartil ketiga (Q3), yaitu 75% nilai terendah. IQR <- Q3 - Q1: Menghitung IQR atau selisih antara Q3 dan Q1. lower_bound <- Q1 - 1.5 * IQR dan upper_bound <- Q3 + 1.5 * IQR: Ini adalah rumus standar untuk menentukan batas bawah dan atas. Setiap nilai di luar batas ini dianggap sebagai outlier. outliers <- ...: Baris ini menyaring data untuk menemukan nilai-nilai yang berada di luar batas yang sudah dihitung. cat("Nilai outlier pada pendapatan:", outliers, "\n"): Menampilkan nilai-nilai yang teridentifikasi sebagai outlier. Berdasarkan data ini, outputnya akan menunjukkan 15000, yang secara signifikan lebih tinggi dari pendapatan lainnya.

c. Praktik menyiapkan Data

```
# 1. Membuat dataset
data <- data.frame(
  id = c(1, 1, 2, 3, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18,
        19, 20, 21, 22, 23, 24, 25, 26, 27, 28),
  umur = c(25, 25, 30, 22, 22, 35, 28, 40, 33, 27, 29, NA, 31, 26, 38, 45, 23,
          29, 34, 36, 41, 27, 30, 32, NA, 28, 39, 24, 31, 50),
  pendapatan = c(5000, 5000, 6000, 4500, 4500, 7000, 5500, 8000, 6200, NA,
                 5100, 4900, 7500, 5200, 6800, 9000, 4700, 5300, 6100, 7200,
                 NA, 5400, 6500, 4800, 5100, 5900, 7800, 4600, 6700, 15000),
  kategori = c("PNS", "PNS", "Swasta", "Wirausaha", "Wirausaha", "PNS",
              "Swasta", "PNS", "Wirausaha", "Swasta", "PNS", "Swasta",
              "PNS", "Wirausaha", "Swasta", "PNS", "Wirausaha", "Swasta",
              "PNS", "Swasta", "Wirausaha", "PNS", "Swasta", "Wirausaha",
              "PNS", "Swasta", "PNS", "Wirausaha", "Swasta", "PNS")
)
print(data)

# Muat paket yang diperlukan
library(dplyr)
library(ggplot2)

# 2. Persiapan Data

# a. Menangani nilai hilang
cat("== a. Menangani Nilai Hilang ==\n")
# Cek jumlah NA
cat("Jumlah NA per kolom sebelum penanganan:\n")
print(colSums(is.na(data)))

# Opsi 1: Menghapus baris yang ada NA
data_no_na <- na.omit(data)
cat("\nOpsi 1 menghapus baris yang ada NA\n")
cat("Jumlah baris setelah menghapus NA:", nrow(data_no_na), "\n")

# Opsi 2: Mengisi NA dengan median untuk umur dan pendapatan
data_imputed <- data
data_imputed$umur[is.na(data_imputed$umur)] <- median(data_imputed$umur, na.rm = TRUE)
data_imputed$pendapatan[is.na(data_imputed$pendapatan)] <-
  median(data_imputed$pendapatan, na.rm = TRUE)
cat("\nOpsi 2 Mengisi NA dengan median untuk umur dan pendapatan\n")
cat("Jumlah NA per kolom setelah imputasi:\n")
print(colSums(is.na(data_imputed)))
cat("Jumlah baris setelah mengisi NA dengan median:", nrow(data_imputed), "\n")

# b. Menghapus data duplikat
cat("\n== b. Menghapus Data Duplikat ==\n")
```

```

cat("Jumlah baris duplikat:", sum(duplicated(data_imputed)), "\n")
data_no_duplicates <- distinct(data_imputed)
cat("Jumlah baris setelah menghapus duplikat:", nrow(data_no_duplicates), "\n")

# c. Memastikan tipe data sesuai
cat("\n==== c. Memastikan Tipe Data Sesuai ====\n")
# Cek tipe data
cat("Tipe data sebelum konversi:\n")
print(str(data_no_duplicates))

# Konversi tipe data
data_no_duplicates$kategori <- as.factor(data_no_duplicates$kategori)
data_no_duplicates$umur <- as.numeric(data_no_duplicates$umur)
data_no_duplicates$pendapatan <- as.numeric(data_no_duplicates$pendapatan)
cat("Tipe data setelah konversi:\n")
print(str(data_no_duplicates))

# d. Menangani outlier (Metode IQR)
cat("\n==== d. Menangani Outlier ====\n")
Q1 <- quantile(data_no_duplicates$pendapatan, 0.25, na.rm = TRUE)
Q3 <- quantile(data_no_duplicates$pendapatan, 0.75, na.rm = TRUE)
IQR <- Q3 - Q1
lower_bound <- Q1 - 1.5 * IQR
upper_bound <- Q3 + 1.5 * IQR
cat("Batas bawah:", lower_bound, "\n")
cat("Batas atas:", upper_bound, "\n")

# Identifikasi outlier
outliers <- data_no_duplicates$pendapatan[data_no_duplicates$pendapatan <
lower_bound |                                     data_no_duplicates$pendapatan >
upper_bound]
cat("Nilai outlier pada pendapatan:", outliers, "\n")

# Hapus outlier
data_no_outliers <- filter(data_no_duplicates,
                           pendapatan >= lower_bound & pendapatan <= upper_bound)
cat("Jumlah baris setelah menghapus outlier:", nrow(data_no_outliers), "\n")

# e. Membuat variabel baru
cat("\n==== e. Membuat Variabel Baru ====\n")
data_with_new_var <- mutate(data_no_outliers,
                            log_pendapatan = log(pendapatan), # Transformasi log
                            umur_kategori = case_when(
                                umur < 30 ~ "Muda",
                                umur >= 30 & umur < 40 ~ "Dewasa",
                                TRUE ~ "Lansia"
                            ))
cat("Beberapa baris dengan variabel baru:\n")
print(head(data_with_new_var))

# f. Memfilter data
cat("\n==== f. Memfilter Data ====\n")
data_filtered <- filter(data_with_new_var,
                         umur >= 18,
                         kategori %in% c("PNS", "Swasta"))
cat("Jumlah baris setelah memfilter (umur >= 18, kategori PNS/Swasta):",
    nrow(data_filtered), "\n")
print(head(data_filtered))

# Simpan data yang sudah disiapkan
write.csv(data_filtered, "data_prepared.csv", row.names = FALSE)
cat("Data disimpan sebagai 'data_prepared.csv'\n")

```

Pembahasan: pada praktik ini kode dimulai dengan membuat data.frame bernama data yang sama seperti sebelumnya, lengkap dengan nilai NA dan baris duplikat. print(data): Perintah ini akan mencetak seluruh data frame ke konsol, memberikan gambaran lengkap tentang data awal. Simpan Data write.csv(data_filtered, "data_prepared.csv", row.names = FALSE): Ini adalah langkah terakhir yang sangat praktis. Fungsi ini menyimpan data frame data_filtered ke dalam file CSV di Google Colab. row.names = FALSE memastikan R tidak menambahkan kolom nomor baris di dalam file

Output

```

id umur pendapatan kategori
1 1 25 5000 PNS
2 1 25 5000 PNS
3 2 30 6000 Swasta
4 3 22 4500 Wirausaha
5 3 22 4500 Wirausaha
6 4 35 7000 PNS
7 5 28 5500 Swasta
8 6 40 8000 PNS
9 7 33 6200 Wirausaha
10 8 27 NA Swasta
11 9 29 5100 PNS
12 10 NA 4900 Swasta
13 11 31 7500 PNS
14 12 26 5200 Wirausaha
15 13 38 6800 Swasta
16 14 45 9000 PNS
17 15 23 4700 Wirausaha
18 16 29 5300 Swasta
19 17 34 6100 PNS
20 18 36 7200 Swasta
21 19 41 NA Wirausaha
22 20 27 5400 PNS
23 21 30 6500 Swasta
24 22 32 4800 Wirausaha
25 23 NA 5100 PNS
26 24 28 5900 Swasta
27 25 39 7800 PNS
28 26 24 4600 Wirausaha
29 27 31 6700 Swasta
30 28 50 15000 PNS
== a. Menangani Nilai Hilang ==
Jumlah NA per kolom sebelum penanganan:
id umur pendapatan kategori
0 2 2 0

Opsi 1 menghapus baris yang ada NA
Jumlah baris setelah menghapus NA: 26

Opsi 2 Mengisi NA dengan median untuk umur dan pendapatan
Jumlah NA per kolom setelah imputasi:
id umur pendapatan kategori
0 0 0 0
Jumlah baris setelah mengisi NA dengan median: 30

== b. Menghapus Data Duplikat ==
Jumlah baris duplikat: 2
Jumlah baris setelah menghapus duplikat: 28

== c. Memastikan Tipe Data Sesuai ==
Tipe data sebelum konversi:
'data.frame': 28 obs. of 4 variables:
 $ id : num 1 2 3 4 5 6 7 8 9 10 ...
 $ umur : num 25 30 22 35 28 40 33 27 29 30 ...
 $ pendapatan: num 5000 6000 4500 7000 5500 8000 6200 5700 5100 4900 ...
 $ kategori : chr "PNS" "Swasta" "Wirausaha" "PNS" ...
NULL
Tipe data setelah konversi:
'data.frame': 28 obs. of 4 variables:
 $ id : num 1 2 3 4 5 6 7 8 9 10 ...
 $ umur : num 25 30 22 35 28 40 33 27 29 30 ...
 $ pendapatan: num 5000 6000 4500 7000 5500 8000 6200 5700 5100 4900 ...
 $ kategori : Factor w/ 3 levels "PNS","Swasta",..: 1 2 3 1 2 1 3 2 1 2 ...
NULL

== d. Menangani Outlier ==
Batas bawah: 2475
Batas atas: 9475
Nilai outlier pada pendapatan: 15000
Jumlah baris setelah menghapus outlier: 27

== e. Membuat Variabel Baru ==
Beberapa baris dengan variabel baru:
id umur pendapatan kategori log_pendapatan umur_kategori
1 1 25 5000 PNS 8.517193 Muda
2 2 30 6000 Swasta 8.699515 Dewasa
3 3 22 4500 Wirausaha 8.411833 Muda
4 4 35 7000 PNS 8.853665 Dewasa
5 5 28 5500 Swasta 8.612503 Muda
6 6 40 8000 PNS 8.987197 Lansia

== f. Memfilter Data ==
Jumlah baris setelah memfilter (umur >= 18, kategori PNS/Swasta): 20
id umur pendapatan kategori log_pendapatan umur_kategori
1 1 25 5000 PNS 8.517193 Muda
2 2 30 6000 Swasta 8.699515 Dewasa
3 4 35 7000 PNS 8.853665 Dewasa
4 5 28 5500 Swasta 8.612503 Muda
5 6 40 8000 PNS 8.987197 Lansia
6 8 27 5700 Swasta 8.648221 Muda
Data disimpan sebagai 'data_prepared.csv'

```

Pembahasan:

a. Menangani Nilai Hilang (NA)

Kode ini menunjukkan dua opsi umum untuk menangani NA:

Opsi 1: Menghapus baris yang ada NA

`data_no_na <- na.omit(data)`: Fungsi `na.omit()` adalah cara cepat dan sederhana untuk menghapus setiap baris yang memiliki setidaknya satu nilai NA. Outputnya: Jumlah baris setelah menghapus NA: 26. Ini menunjukkan 4 baris yang mengandung NA (dua di umur dan dua di pendapatan) telah dihapus.

Opsi 2: Mengisi NA dengan median (Imputasi)

`data_imputed <- data`: Pertama, buat salinan data agar data asli tidak berubah.
`data_imputed$umur[is.na(data_imputed$umur)] <- median(...)`: Baris ini menemukan nilai NA di kolom umur (`is.na(...)`) lalu menggantinya dengan nilai median dari kolom umur. `na.rm = TRUE` sangat penting, karena ia memberitahu R untuk mengabaikan nilai NA saat menghitung median. Jika tidak, median akan bernilai NA. Langkah serupa dilakukan untuk kolom pendapatan. Outputnya: Jumlah NA per kolom setelah imputasi: `id = 0, umur = 0, pendapatan = 0, kategori = 0`. Ini mengonfirmasi bahwa semua nilai hilang sudah diisi.

b. Menghapus Data Duplikat

`sum(duplicated(data_imputed))`: Menghitung jumlah baris duplikat. Outputnya adalah 2. `data_no_duplicates <- distinct(data_imputed)`: Fungsi `distinct()` dari paket `dplyr` adalah cara terbaik untuk menghapus baris yang sepenuhnya duplikat. Ia akan menyimpan hanya baris unik. Outputnya: Jumlah baris setelah menghapus duplikat: 28. Ini menunjukkan dua baris duplikat (yang memiliki `id` 1 dan 3) telah dihapus, dan data sekarang memiliki 28 baris unik.

c. Memastikan Tipe Data Sesuai

`str(data_no_duplicates)`: Dicetak dua kali, sebelum dan sesudah konversi. Ini memungkinkan melihat perubahannya. `data_no_duplicates$kategori <- as.factor(...)`: Mengonversi kolom kategori menjadi tipe data factor.
`data_no_duplicates$umur <- as.numeric(...)` dan `data_no_duplicates$pendapatan <- as.numeric(...)`: Meskipun kemungkinan besar tipe data ini sudah numerik, langkah ini memastikan bahwa tidak ada masalah yang terlewat, seperti angka yang dibaca sebagai karakter.

d. Menangani Outlier (Metode IQR)

Ini adalah proses yang sama seperti di penjelasan sebelumnya, di mana kita menggunakan metode Interquartile Range (IQR) untuk menemukan batas bawah dan atas. `outliers <- ...`: Baris ini akan mengidentifikasi nilai 15000 sebagai outlier di kolom pendapatan. `data_no_outliers <- filter(...)`: Ini adalah langkah penting. Fungsi `filter()` dari `dplyr` digunakan untuk memilih baris yang memenuhi kondisi tertentu. Di sini hanya menyimpan baris yang nilai pendapatannya berada di antara `lower_bound` dan `upper_bound`. Outputnya: Jumlah baris setelah menghapus outlier: 27. Ini menunjukkan satu baris (dengan pendapatan 15000) telah dihapus.

e. Membuat Variabel Baru

`data_with_new_var <- mutate(...)`: Fungsi `mutate()` dari `dplyr` adalah cara efisien untuk membuat kolom baru tanpa mengubah kolom yang sudah ada.
`log_pendapatan = log(pendapatan)`: Membuat kolom baru bernama `log_pendapatan` yang berisi nilai logaritma dari kolom pendapatan. Transformasi log sering digunakan untuk menormalisasi data yang memiliki sebaran tidak merata, seperti pendapatan. `umur_kategori = case_when(...)`: Ini adalah cara yang fleksibel dan kuat untuk membuat variabel kategorikal baru berdasarkan kondisi. `umur < 30 ~ "Muda"`: Jika umur kurang dari 30, beri label "Muda". `umur >= 30 & umur < 40 ~ "Dewasa"`: Jika umur di antara 30 dan 40, beri label "Dewasa". `TRUE`

~ "Lansia": Semua nilai lainnya (yang tidak memenuhi kondisi di atas) diberi label "Lansia".

f. Memfilter Data

data_filtered <- filter(...): Menggunakan filter() lagi, tetapi kali ini untuk memilih baris yang diinginkan untuk analisis lebih lanjut. umur ≥ 18 : Menyimpan hanya baris di mana umur setidaknya 18. kategori %in% c("PNS", "Swasta"): Menjaga hanya baris di mana kolom kategori bernilai "PNS" atau "Swasta". Outputnya akan menunjukkan jumlah baris yang tersisa dan beberapa baris pertama dari data yang sudah disaring.

B. PEMBAHASAN LATIHAN

Lihat folder sampel_data yang ada di Google Colab

1. Impor dataset california_housing_tes.csv
2. Tampilkan 6 data di awal.
3. Lakukan pemeriksaan data untuk melihat struktur data, dimensi data, ringkasan data, data hilang, data duplikat, outlier.
4. Lakukan penyiapan data dengan menghapus data hilang dan data yang duplikat.

```
# 1. Impor dataset california_housing_test.csv
cat("== Impor Dataset ==\n")
data <- read.csv("/content/sample_data/california_housing_test.csv")
cat("Dataset 'california_housing_test.csv' berhasil diimpor.\n")

# 2. Tampilkan 6 data di awal.
cat("\n== 6 Data Pertama ==\n")
print(head(data))

# 3. Lakukan pemeriksaan data
cat("\n== Pemeriksaan Data ==\n")

# a. Memeriksa struktur data
cat("\n== a. Memeriksa Struktur Data ==\n")
str(data)

# b. Memeriksa dimensi data
cat("\n== b. Memeriksa Dimensi Data ==\n")
cat("Dimensi (baris, kolom):", dim(data), "\n")
cat("Jumlah baris:", nrow(data), "\n")
cat("Jumlah kolom:", ncol(data), "\n")
cat("Nama kolom:", names(data), "\n")

# c. Ringkasan statistik
cat("\n== c. Ringkasan Statistik ==\n")
summary(data)

# d. Mengecek nilai hilang
cat("\n== d. Mengecek Nilai Hilang ==\n")
```

```

cat("Jumlah NA per kolom:\n")
print(colSums(is.na(data)))
cat("Jumlah baris lengkap (tanpa NA):", sum(complete.cases(data)), "\n")

# e. Mengecek duplikat
cat("\n==== e. Mengecek Duplikat ====\n")
cat("Jumlah baris duplikat:", sum(duplicated(data)), "\n")
cat("Baris duplikat:\n")
print(data[duplicated(data), ])

# f. Mengecek outlier (contoh pada kolom median_income)
cat("\n==== f. Mengecek Outlier (median_income) ====\n")
Q1 <- quantile(data$median_income, 0.25, na.rm = TRUE)
Q3 <- quantile(data$median_income, 0.75, na.rm = TRUE)
IQR <- Q3 - Q1
lower_bound <- Q1 - 1.5 * IQR
upper_bound <- Q3 + 1.5 * IQR
cat("Batas bawah (Q1 - 1.5 * IQR):", lower_bound, "\n")
cat("Batas atas (Q3 + 1.5 * IQR):", upper_bound, "\n")
outliers <- data$median_income[data$median_income < lower_bound |
                                data$median_income > upper_bound &
                                !is.na(data$median_income)]
cat("Nilai outlier pada median_income:", outliers, "\n")

# 4. Lakukan penyiapan data

# a. Menghapus data hilang
cat("\n==== a. Menghapus Data Hilang ====\n")
data_no_na <- na.omit(data)
cat("Jumlah baris setelah menghapus NA:", nrow(data_no_na), "\n")

# b. Menghapus data duplikat
cat("\n==== b. Menghapus Data Duplikat ====\n")
data_prepared <- unique(data_no_na) # unique() works for rows in data frames
cat("Jumlah baris setelah menghapus duplikat:", nrow(data_prepared), "\n")

cat("\n==== Data Siap Digunakan (Setelah NA dan Duplikat Dihapus) ====\n")
print(head(data_prepared))

```

Pembahasan: pada latihan pertama kode dimulai dengan memuat dataset yang sudah tersedia di google colab. `data <- read.csv(...)`: Fungsi ini membaca file CSV yang merupakan standar di R. Jalur /content/sample_data/california_housing_test.csv adalah lokasi tetap file sampel yang disediakan oleh Google Colab. Seluruh data dari file ini dimuat ke dalam variabel `data`. Output: Mengonfirmasi bahwa file telah berhasil diimpor. `print(head(data))` Fungsi `head()` menampilkan 6 baris pertama dari data frame. Ini adalah cara cepat untuk memverifikasi bahwa data telah dibaca dengan benar dan kolom-kolomnya (seperti `longitude`, `latitude`, `median_income`) terlihat seperti yang diharapkan. Output Menampilkan 6 baris pertama dengan 9 kolom yang sesuai, ini menunjukkan data koordinat geografis dan statistik perumahan di California.

Output

```


    === Import Dataset ===
    Dataset 'california_housing_test.csv' berhasil diimpor.

    === 6 Data Pertama ===
    longitude latitude housing_median_age total_rooms total_bedrooms population
    1   -122.05  37.37          27      3885       661     1537
    2   -118.30  34.26          43      1510       310     809
    3   -117.81  33.78          27      3589       507     1484
    4   -118.36  33.82          28       67        15      49
    5   -119.67  36.33          19      1241       244     850
    6   -119.56  36.51          37      1018       213     663
    households median_income median_house_value
    1         606           6.6085      344700
    2         277           3.5990      176500
    3         495           5.7934      270500
    4          11           6.1359      330000
    5         237           2.9375      81700
    6         204           1.6635      67000

    === Pemeriksaan Data ===

    === a. Memeriksa Struktur Data ===
    'data.frame': 3000 obs. of 9 variables:
    $ longitude : num -122 -118 -118 -118 -120 ...
    $ latitude  : num 37.4 34.3 33.8 33.8 36.3 ...
    $ housing_median_age: num 27 43 27 28 19 37 43 19 15 31 ...
    $ total_rooms: num 3885 1510 3589 67 1241 ...
    $ total_bedrooms: num 661 310 507 15 244 213 225 471 617 632 ...
    $ population : num 1537 809 1484 49 854 ...
    $ households : num 606 277 495 11 237 204 218 441 599 603 ...
    $ median_income : num 6.61 3.6 5.79 6.14 2.94 ...
    $ median_house_value: num 344700 176500 270500 330000 81700 ...

    === b. Memeriksa Dimensi Data ===
    Dimensi (baris, kolom): 3000 9
    Jumlah baris: 3000
    Jumlah kolom: 9
    Nama kolom: longitude latitude housing_median_age total_rooms population households median_income median_house_value

    === c. Ringkasan Statistik ===
    longitude      latitude      housing_median_age      total_rooms
    Min. :-124.2  Min. :32.56  Min. : 1.00  Min. : 6
    1st Qu.:-121.8 1st Qu.:33.93  1st Qu.:18.00  1st Qu.: 1401
    Median : -118.5 Median :34.27  Median :29.00  Median : 2106
    Mean   : -119.6 Mean  :35.64  Mean  :28.85  Mean  : 2600
    3rd Qu.:-118.0 3rd Qu.:37.69  3rd Qu.:37.00  3rd Qu.: 3129
    Max.   : -114.5 Max.  :41.92  Max.  :52.00  Max.  :30450
    total_bedrooms      population      households      median_income
    Min. : 2  Min. : 5  Min. : 2.0  Min. : 0.4999
    1st Qu.: 291  1st Qu.: 780  1st Qu.: 273.0  1st Qu.: 2.5440
    Median : 437  Median :1155  Median : 409.5  Median : 3.4872
    Mean   : 530  Mean  :1403  Mean  : 489.9  Mean  : 3.8073
    3rd Qu.: 636  3rd Qu.: 1743  3rd Qu.: 597.2  3rd Qu.: 4.6565
    Max.   :5419  Max.  :11935  Max.  :4930.0  Max.  :15.0001
    median_house_value
    Min. : 22500
    1st Qu.:121200
    Median :177650
    Mean   :205846
    3rd Qu.:263975
    Max.   :500001

    === d. Mengecek Nilai Hilang ===
    Jumlah NA per kolom:
    longitude      latitude      housing_median_age      total_rooms
    0             0             0                 0
    total_bedrooms      population      households      median_income
    0             0             0                 0
    median_house_value
    0
    Jumlah baris lengkap (tanpa NA): 3000

    === e. Mengecek Duplikat ===
    Jumlah baris duplikat: 0
    Baris duplikat:
    [1] longitude      latitude      housing_median_age      total_rooms
    [5] total_bedrooms      population      households      median_income
    [9] median_house_value
    <0 rows> (or 0-length row.names)

    === f. Mengecek Outlier (median_income) ===
    Batas bawah (Q1 - 1.5 * IQR): -0.6247125
    Batas atas (Q3 + 1.5 * IQR): 7.825187
    Nilai outlier pada median_income: 15.0001 10.1007 13.6623 10.5981 12.6417 8.1926 15.0001 8.5938 9.8214 10.9722 10.476 12.3767 10.9529 11.806 10.8111

    === a. Menghapus Data Hilang ===
    Jumlah baris setelah menghapus NA: 3000

    === b. Menghapus Data Duplikat ===
    Jumlah baris setelah menghapus duplikat: 3000

    === Data Siap Digunakan (Setelah NA dan Duplikat Dihapus) ===
    longitude latitude housing_median_age total_rooms total_bedrooms population
    1   -122.05  37.37          27      3885       661     1537
    2   -118.30  34.26          43      1510       310     809
    3   -117.81  33.78          27      3589       507     1484
    4   -118.36  33.82          28       67        15      49
    5   -119.67  36.33          19      1241       244     850
    6   -119.56  36.51          37      1018       213     663
    households median_income median_house_value
    1         606           6.6085      344700
    2         277           3.5990      176500
    3         495           5.7934      270500
    4          11           6.1359      330000
    5         237           2.9375      81700
    6         204           1.6635      67000


```

Pembahasan :

a. Memeriksa Struktur Data

`str(data)` Fungsi `str()` memberikan ringkasan struktur internal data frame. Output '`data.frame`' 3000 obs. of 9 variables Mengonfirmasi bahwa dataset adalah data frame dengan 3000 observasi (baris) dan 9 variabel (kolom). Semua variabel teridentifikasi sebagai tipe num (numerik), yang berarti semua data berupa angka desimal.

b. Memeriksa Dimensi Data

`dim(), nrow(), ncol()` Fungsi-fungsi ini memberikan informasi dimensi yang lebih spesifik. `names()` Menampilkan semua nama kolom. Output Semua perintah mengonfirmasi data berukuran 3000 baris dan 9 kolom

c. Ringkasan Statistik

`summary(data)` Fungsi ini menghitung statistik deskriptif untuk setiap kolom numerik. Output Menunjukkan nilai Min., Max., Median, Mean, Q1, dan Q3 untuk setiap variabel. Misalnya, pada kolom `median_income`, nilai minimum adalah \$0.4999 (ribu USD) dan maksimumnya adalah \$15.0001 (ribu USD).

d. Mengecek Nilai Hilang (NA)

`colSums(is.na(data))` Menghitung total nilai NA (hilang) per kolom. `sum(complete.cases(data))` Menghitung jumlah baris yang lengkap (tidak ada NA). Output Jumlah NA per kolom ... 0 ...: akan menunjukkan bahwa tidak ada nilai hilang sama sekali di dataset ini (semua kolom bernilai 0). Jumlah baris lengkap (tanpa NA) 3000: Karena tidak ada NA, semua baris lengkap.

e. Mengecek Duplikat

`sum(duplicated(data))` ini untuk menghitung total baris yang merupakan duplikat penuh. `data[duplicated(data),]`, untuk mencetak baris-baris yang duplikat tersebut. Output Jumlah baris duplikat: 0 ini mengonfirmasi bahwa tidak ada baris yang merupakan duplikat di dataset ini.

f. Mengecek Outlier (Median Income)

Perhitungan ini menemukan Q1 (25% kuartil) dan Q3 (75% kuartil), kemudian menggunakan rumus Batas= $Q \pm 1.5 \times IQR$. Nilai di luar batas ini dianggap outlier. Output Batas bawah ($Q1 - 1.5 * IQR$): -0.6247125 Batas atas ($Q3 + 1.5 * IQR$): 7.825187 Nilai outlier pada `median_income`: 15.0001 10.1007 ...: Karena Batas Atas hanya \$7.825, semua nilai `median_income` yang lebih besar dari itu dianggap outlier. Output menunjukkan sejumlah nilai pendapatan yang sangat tinggi (di atas \$7.825, atau \$78.250 USD) yang terdeteksi sebagai outlier statistik.

Penyiapan data sederhana meskipun pemeriksaan data menunjukkan tidak ada NA atau duplikat, bagian ini akan mendemonstrasikan bagaimana melakukan pembersihan jika seandainya ada.

a. Menghapus Data Hilang

`data_no_na <- na.omit(data)`: Menghapus semua baris yang mengandung NA. Outputnya Jumlah baris setelah menghapus NA: 3000. Karena data awal bersih dari NA, jumlah baris tidak berubah.

b. Menghapus Data Duplikat

`data_prepared <- unique(data_no_na)`: Fungsi `unique()` akan menghapus baris duplikat. Outputnya Jumlah baris setelah menghapus duplikat: 3000. Karena data awal bersih dari duplikat, jumlah baris tidak berubah.

C. PEMBAHASAN TUGAS

Download dan simpan data pada Google Colab dataset pada link

<https://www.kaggle.com/datasets/mohankrishnathalla/diabetes-health-indicators-dataset>.

1. Impor dataset tersebut
2. Tampilkan 6 data di awal.
3. Lakukan pemeriksaan data untuk melihat struktur data, dimensi data, ringkasan data, data hilang, data duplikat, outlier.n
4. Lakukan penyiapan data dengan menghapus data hilang dan data yang duplikat.

```

# 1. Impor dataset
cat("==> 1. Impor Dataset ==>\n")
# Sesuaikan nama file jika berbeda
data <- read_csv("/content//diabetes_dataset.csv") # Updated file path
cat("Dataset '/content//diabetes_dataset.csv' berhasil diimpor.\n") # Updated
success message

# 2. Tampilkan 6 data di awal
cat("\n==> 2. Tampilkan 6 Data Pertama (Head) ==>\n")
print(head(data))

# 3. Lakukan pemeriksaan data (EDA - Exploratory Data Analysis)
cat("\n==> 3. Pemeriksaan Data (EDA) ==>\n")

# a. Memeriksa struktur data
cat("\n==> a. Struktur Data (str) ==>\n")
str(data)

# b. Memeriksa dimensi data
cat("\n==> b. Dimensi Data (rows, columns) ==>\n")
cat("Dimensi (baris, kolom):", dim(data), "\n")
cat("Jumlah baris:", nrow(data), "\n")
cat("Jumlah kolom:", ncol(data), "\n")
cat("Nama kolom:", names(data), "\n")

# c. Ringkasan statistik
cat("\n==> c. Ringkasan Statistik (summary) ==>\n")
print(summary(data))

# d. Mengecek nilai hilang (NA)
cat("\n==> d. Mengecek Nilai Hilang (NA) ==>\n")
cat("Jumlah NA per kolom:\n")
print(colSums(is.na(data)))
cat("Jumlah baris lengkap (tanpa NA):", sum(complete.cases(data)), "\n")

# e. Mengecek duplikat
cat("\n==> e. Mengecek Duplikat ==>\n")
total_duplikat <- sum(duplicated(data))
cat("Jumlah baris duplikat:", total_duplikat, "\n")
if (total_duplikat > 0) {
  cat("Beberapa contoh baris duplikat:\n")
  print(data[duplicated(data), ] |> head())
} else {
  cat("Tidak ditemukan baris duplikat.\n")
}

```

```

}

# f. Mengecek outlier (Contoh: BMI)
cat("\n==== f. Mengecek Outlier (BMI) ====\n")
# Perhitungan IQR
Q1_bmi <- quantile(data$BMI, 0.25, na.rm = TRUE)
Q3_bmi <- quantile(data$BMI, 0.75, na.rm = TRUE)
IQR_bmi <- Q3_bmi - Q1_bmi
lower_bound_bmi <- Q1_bmi - 1.5 * IQR_bmi
upper_bound_bmi <- Q3_bmi + 1.5 * IQR_bmi

cat("Batas bawah BMI (Q1 - 1.5 * IQR):", lower_bound_bmi, "\n")
cat("Batas atas BMI (Q3 + 1.5 * IQR):", upper_bound_bmi, "\n")

# Identifikasi outlier
outliers_bmi <- data$BMI[data$BMI < lower_bound_bmi | data$BMI > upper_bound_bmi]
cat("Jumlah outlier BMI yang terdeteksi:", length(outliers_bmi), "\n")
cat("Contoh nilai outlier BMI:", unique(outliers_bmi) |> head(10), "\n")

# 4. Lakukan penyiapan data (Data Cleaning)
cat("\n==== 4. Penyiapan Data (Pembersihan) ====\n")

# a. Menghapus data hilang (NA)
data_no_na <- na.omit(data)
cat("Jumlah baris setelah menghapus NA:", nrow(data_no_na), " (Awal: ", nrow(data), ")\n")

# b. Menghapus data duplikat
# Gunakan fungsi distinct() dari dplyr untuk menghapus baris duplikat
data_prepared <- data_no_na %>% distinct()

cat("Jumlah baris setelah menghapus duplikat:", nrow(data_prepared), "\n")

cat("\n==== Data Siap Digunakan ====\n")
cat("Dataset akhir yang bersih memiliki", nrow(data_prepared), "baris dan", ncol(data_prepared), "kolom.\n")
print(head(data_prepared))

```

Output

```

  === 1. Impor Dataset ===
  Rows: 100000 Columns: 31
  └─ Column specification ───────────────────────────────────────────────────
  Delimiter: ","
  chr (7): gender, ethnicity, education_level, income_level, employment_status...
  dbl (24): age, alcohol_consumption_per_week, physical_activity_minutes_per_w...
  
  i Use `spec()` to retrieve the full column specification for this data.
  i Specify the column types or set `show_col_types = FALSE` to quiet this message.
  Dataset '/content//diabetes_dataset.csv' berhasil diimpor.

  === 2. Tampilkan 6 Data Pertama (Head) ===
# A tibble: 6 × 31
  age gender ethnicity education_level income_level employment_status
  <dbl> <chr>   <chr>    <chr>      <chr>        <chr>
1 58 Male Asian Highschool Lower-Middle Employed
2 48 Female White Highschool Middle       Employed
3 60 Male Hispanic Highschool Middle      Unemployed
4 74 Female Black Highschool Low        Retired
5 46 Male White Graduate Middle      Retired
6 46 Female White Highschool Upper-Middle Employed
# i 25 more variables: smoking_status <chr>,
#   alcohol_consumption_per_week <dbl>,
#   physical_activity_minutes_per_week <dbl>, diet_score <dbl>,
#   sleep_hours_per_day <dbl>, screen_time_hours_per_day <dbl>,
#   family_history_diabetes <dbl>, hypertension_history <dbl>,
#   cardiovascular_history <dbl>, bmi <dbl>, waist_to_hip_ratio <dbl>,
#   systolic_bp <dbl>, diastolic_bp <dbl>, heart_rate <dbl>, ...

```

Pembahasan : Output menunjukkan bahwa sudah berhasil mengimpor dataset dengan sukses. Baris Rows: 100000 Columns: 31 dan Dataset '/content//diabetes_dataset.csv' berhasil diimpor ini adalah konfirmasi bahwa data telah dimuat ke dalam R. Output ini juga memberikan tipe data kolom-kolom. R secara otomatis mendeteksi bahwa ada 7 kolom bertipe chr (karakter) seperti gender dan ethnicity, serta 24 kolom bertipe dbl (double/numerik) seperti age dan bmi.

Tampilan awal menunjukkan dataset yang mencakup demografi (age, gender, ethnicity), faktor gaya hidup (smoking_status, alcohol_consumption_per_week, sleep_hours_per_day), dan indikator klinis rinci (bmi, systolic_bp, hba1c, insulin_level). Variabel target utama kemungkinan adalah diagnosed_diabetes (0 atau 1) atau diabetes_stage (karakter).879kj1

```

  === 3. Pemeriksaan Data (EDA) ===
  === a. Struktur Data (str) ===
spc_tbl_ [100,000 × 31] (S3: spec_tbl_df/tbl_df/tbl/data.frame)
$ age           : num [1:100000] 58 48 60 74 46 46 75 62 42 59 ...
$ gender        : chr [1:100000] "Male" "Female" "Male" "Female" ...
$ ethnicity     : chr [1:100000] "Asian" "White" "Hispanic" "Black" ...
$ education_level: chr [1:100000] "Highschool" "Highschool" "Highschool" "Highschool" ...
$ income_level  : chr [1:100000] "Lower-Middle" "Middle" "Low" ...
$ employment_status: chr [1:100000] "Employed" "Employed" "Unemployed" "Retired" ...
$ smoking_status: chr [1:100000] "Never" "Former" "Never" "Never" ...
$ alcohol_consumption_per_week: num [1:100000] 0 1 1 0 1 2 0 1 1 3 ...
$ physical_activity_minutes_per_week: num [1:100000] 215 143 57 49 109 124 53 75 114 86 ...
$ diet_score     : num [1:100000] 5.7 6.7 6.4 3.4 7.2 9.9 2.4 4.1 6.7 8.2 ...
$ sleep_hours_per_day: num [1:100000] 7.9 6.5 10 6.6 7.4 6.2 7.8 9 8.5 5.3 ...
$ screen_time_hours_per_day: num [1:100000] 7.9 8.7 8.1 5.2 5.5 4.8 12.9 8.5 7.4 ...
$ family_history_diabetes: num [1:100000] 0 0 1 0 0 0 0 0 0 0 ...
$ hypertension_history: num [1:100000] 0 0 0 0 0 0 1 1 0 0 ...
$ cardiovascular_history: num [1:100000] 0 0 0 0 0 0 0 1 1 0 ...
$ bmi           : num [1:100000] 30.5 23.1 22.2 26.8 21.2 26.1 25.1 23.9 24.7 26.7 ...
$ waist_to_hip_ratio: num [1:100000] 0.89 0.8 0.81 0.88 0.78 0.85 0.88 0.86 0.84 0.81 ...
$ systolic_bp   : num [1:100000] 134 129 115 120 92 95 129 128 103 124 ...
$ diastolic_bp  : num [1:100000] 78 76 73 93 67 81 77 83 71 81 ...
$ heart_rate    : num [1:100000] 68 67 74 68 67 57 81 76 72 70 ...
$ cholesterol_total: num [1:100000] 239 116 213 171 210 218 238 241 187 188 ...
$ hdl_cholesterol: num [1:100000] 41 55 66 50 52 61 46 49 33 52 ...
$ ldl_cholesterol: num [1:100000] 168 50 99 79 125 119 161 159 132 103 ...
$ triglycerides: num [1:100000] 145 30 36 140 166 179 155 128 98 184 ...
$ glucose_fasting: num [1:100000] 136 93 118 139 137 108 101 110 116 76 ...
$ glucose_postprandial: num [1:100000] 236 150 195 253 184 133 100 189 172 109 ...
$ insulin_level: num [1:100000] 6.38 2 5.07 5.28 12.74 ...
$ hba1c          : num [1:100000] 8.18 5.63 7.51 9.03 7.2 6.03 5.24 7.04 6.9 4.99 ...
$ diabetes_risk_score: num [1:100000] 29.6 23 44.7 38.2 23.5 23.5 36.1 34.2 26.7 30 ...
$ diabetes_stage: chr [1:100000] "Type 2" "No Diabetes" "Type 2" "Type 2" ...
$ diagnosed_diabetes: num [1:100000] 1 0 1 1 1 0 0 1 1 0 ...

```

Pembahasan : A. Struktur Data (str) Tujuan: Memeriksa tipe data dari 31 kolom yang ada.. Variabel seperti age, bmi, hba1c, dan tekanan darah (systolic_bp, diastolic_bp) dikategorikan sebagai numerik (num atau dbl). Variabel seperti gender dan education_level dikategorikan sebagai karakter (chr).

```

⇒ === b. Dimensi Data (rows, columns) ===
Dimensi (baris, kolom): 100000 31
Jumlah baris: 100000
Jumlah kolom: 31
Nama kolom: age gender ethnicity education_level income_level employment_status smoking_status alcohol_consumpt:

⇒ === c. Ringkasan Statistik (summary) ===
      age           gender       ethnicity   education_level
Min.  :18.00        Length:100000    Length:100000    Length:100000
1st Qu.:39.00       Class :character  Class :character  Class :character
Median :50.00       Mode  :character  Mode  :character  Mode  :character
Mean   :50.12
3rd Qu.:61.00
Max.   :90.00

      income_level   employment_status   smoking_status
Length:100000    Length:100000    Length:100000
Class :character  Class :character  Class :character
Mode  :character  Mode  :character  Mode  :character

```

Pembahasan :

b. Dimensi Data. Dimensi (baris, kolom): 100000 31: Ini menunjukkan bahwa dataset yang dianalisis memiliki 100.000 baris (observasi) dan 31 kolom (variabel). Jumlah baris: 100000: Menegaskan jumlah total data yang ada, yang merupakan dataset berukuran sangat besar dan ideal untuk pemodelan machine learning. Jumlah kolom: 31: Mengindikasikan kekayaan data, di mana setiap observasi memiliki 31 atribut atau fitur yang berbeda. Nama kolom: Daftar nama kolom yang sangat beragam, mencakup informasi demografis, gaya hidup, hingga data klinis yang spesifik.

c. Ringkasan Statistik

Bagian ini memberikan gambaran umum tentang distribusi dan tipe data setiap kolom. age: Merupakan variabel numerik (kuantitatif) dengan rentang usia dari 18 hingga 90 tahun, dan rata-rata usia sekitar 50.12 tahun. Distribusi ini menunjukkan bahwa dataset mencakup berbagai kelompok usia dewasa. gender, ethnicity, education_level, income_level, employment_status, smoking_status: Semua kolom ini adalah variabel karakter (kategorikal). Output Length:100000, Class:character, dan Mode:character menegaskan bahwa variabel-variabel ini menyimpan data tekstual atau kategori, bukan angka.

```

⇒ alcohol_consumption_per_week physical_activity_minutes_per_week
Min.  : 0.000          Min.  : 0.0
1st Qu.: 1.000          1st Qu.: 57.0
Median : 2.000          Median :100.0
Mean   : 2.004          Mean   :118.9
3rd Qu.: 3.000          3rd Qu.:160.0
Max.   :10.000          Max.   :833.0

      diet_score   sleep_hours_per_day screen_time_hours_per_day
Min.  : 0.000          Min.  : 3.000          Min.  : 0.500
1st Qu.: 4.800          1st Qu.: 6.300          1st Qu.: 4.300
Median : 6.000          Median : 7.000          Median : 6.000
Mean   : 5.995          Mean   : 6.998          Mean   : 5.996
3rd Qu.: 7.200          3rd Qu.: 7.700          3rd Qu.: 7.700
Max.   :10.000          Max.   :10.000          Max.   :16.800

family_history_diabetes hypertension_history cardiovascular_history
Min.  :0.0000          Min.  :0.0000          Min.  :0.0000
1st Qu.:0.0000          1st Qu.:0.0000          1st Qu.:0.0000
Median :0.0000          Median :0.0000          Median :0.0000
Mean   :0.2194          Mean   :0.2508          Mean   :0.0792
3rd Qu.:0.0000          3rd Qu.:1.0000          3rd Qu.:0.0000
Max.   :1.0000          Max.   :1.0000          Max.   :1.0000

      bmi      waist_to_hip_ratio systolic_bp   diastolic_bp
Min.  :15.00            Min.  :0.6700        Min.  :90.0  Min.  :50.0
1st Qu.:23.20            1st Qu.:0.8200        1st Qu.:106.0 1st Qu.: 70.0
Median :25.60            Median :0.8600        Median :116.0  Median : 75.00
Mean   :25.61            Mean   :0.8561        Mean   :115.8  Mean   : 75.23
3rd Qu.:28.00            3rd Qu.:0.8900        3rd Qu.:125.0 3rd Qu.: 81.00
Max.   :39.20            Max.   :1.0600        Max.   :179.0  Max.   :110.00

      heart_rate   cholesterol_total hdl_cholesterol ldl_cholesterol

```

```

    Min.   : 40.00   Min.   :100    Min.   :20.00   Min.   : 50
    1st Qu.: 64.00   1st Qu.:164    1st Qu.:47.00   1st Qu.: 78
    Median : 70.00   Median :186    Median :54.00   Median :102
    Mean   : 69.63   Mean   :186    Mean   :54.04   Mean   :103
    3rd Qu.: 75.00   3rd Qu.:208    3rd Qu.:61.00   3rd Qu.:126
    Max.   :105.00   Max.   :318    Max.   :98.00   Max.   :263
triglycerides glucose_fasting glucose_postprandial insulin_level
Min.   : 30.0      Min.   :60.0     Min.   : 70          Min.   : 2.000
1st Qu.: 91.0      1st Qu.:102.0   1st Qu.:139        1st Qu.: 5.090
Median :121.0      Median :111.0     Median :160        Median : 8.790
Mean   :121.5      Mean   :111.1     Mean   :160        Mean   : 9.061
3rd Qu.:151.0      3rd Qu.:120.0   3rd Qu.:181        3rd Qu.:12.450
Max.   :344.0      Max.   :172.0     Max.   :287        Max.   :32.220
    hbac          diabetes_risk_score diabetes_stage diagnosed_diabetes
Min.   :4.000      Min.   : 2.70    Length:100000   Min.   : 0.0
1st Qu.:5.970      1st Qu.:23.80    Class :character  1st Qu.: 0.0
Median :6.520      Median :29.00    Mode  :character  Median :1.0
Mean   :6.521      Mean   :30.22    NA's   :100000    Mean   : 0.6
3rd Qu.:7.070      3rd Qu.:35.60    NA's   :100000    3rd Qu.:1.0
Max.   :9.800      Max.   :67.20    NA's   :100000    Max.   :1.0

```

Pembahasan : dilihat dari faktor gaya hidup, Riwayat Kesehatan, biometrik dan klinis, indicator diabetes langsung, variabel hasil . Variabel riwayat kesehatan ini bersifat biner (0 atau 1). Nilai rata-rata secara langsung menunjukkan proporsi responden yang memiliki riwayat tersebut. Proporsi hipertensi (25%) dan riwayat keluarga diabetes (22%) cukup signifikan dan akan menjadi prediktor kuat dalam model diabetes. Rata-rata HbA1c 6.521% berada tepat di ambang diagnosis diabetes ($\geq 6.5\%$). Kuartil 1 (5.97%) menunjukkan 25% populasi berada di zona Pradiabetes (5.7–6.4%).

```

    === d. Mengecek Nilai Hilang (NA) ===
    Jumlah NA per kolom:
            age                  gender
            0                   0
            ethnicity          education_level
            0                   0
            income_level        employment_status
            0                   0
            smoking_status      alcohol_consumption_per_week
            0                   0
physical_activity_minutes_per_week           diet_score
            0                   0
            sleep_hours_per_day screen_time_hours_per_day
            0                   0
family_history_diabetes      hypertension_history
            0                   0
cardiovascular_history             bmi
            0                   0
            waist_to_hip_ratio systolic_bp
            0                   0
            diastolic_bp       heart_rate
            0                   0
            cholesterol_total hdl_cholesterol
            0                   0
            ldl_cholesterol    triglycerides
            0                   0
            glucose_fasting   glucose_postprandial
            0                   0
            insulin_level     hbac
            0                   0
diabetes_risk_score      diabetes_stage
            0                   0
            diagnosed_diabetes
            0

```

Pembahasan : dapat dilihat tidak ada satupun nilai hilang yang secara eksplisit ditandai sebagai NA di seluruh baris. Hal ini menghilangkan kebutuhan untuk imputasi, menjadikan proses pemodelan lebih cepat dan akurat.

Jumlah baris lengkap (tanpa NA): 100000

```

    === e. Mengecek Duplikat ===
Jumlah baris duplikat: 0
Tidak ditemukan baris duplikat.

    === f. Mengecek Outlier (BMI) ===
Warning message:
"Unknown or uninitialised column: `BMI`."
Warning message:
"Unknown or uninitialised column: `BMI`."
Batas bawah BMI (Q1 - 1.5 * IQR): NA
Batas atas BMI (Q3 + 1.5 * IQR): NA
Warning message:
"Unknown or uninitialised column: `BMI`."
Warning message:
"Unknown or uninitialised column: `BMI`."
Warning message:
"Unknown or uninitialised column: `BMI`."
Jumlah outlier BMI yang terdeteksi: 0
Contoh nilai outlier BMI:

```

Pembahasan : Dataset ini bersih dari duplikasi baris sempurna. Setiap observasi (pasien) unik, menjamin bahwa model yang dilatih tidak akan bias oleh data yang berulang.

```
== 4. Penyiapan Data (Pembersihan) ==
Jumlah baris setelah menghapus NA: 100000 (Awal: 100000 )
Jumlah baris setelah menghapus duplikat: 100000

== Data Siap Digunakan ==
Dataset akhir yang bersih memiliki 100000 baris dan 31 kolom.
# A tibble: 6 × 31
  age gender ethnicity education_level income_level employment_status
  <dbl> <chr>   <chr>    <chr>      <chr>      <chr>
1 58   Male     Asian     Highschool Lower-Middle Employed
2 48   Female   White    Highschool Middle     Employed
3 60   Male     Hispanic Highschool Middle     Unemployed
4 74   Female   Black    Highschool Low       Retired
5 46   Male     White    Graduate   Middle     Retired
6 46   Female   White    Highschool Upper-Middle Employed
# i 25 more variables: smoking_status <chr>,
# alcohol_consumption_per_week <dbl>,
# physical_activity_minutes_per_week <dbl>, diet_score <dbl>,
# sleep_hours_per_day <dbl>, screen_time_hours_per_day <dbl>,
# family_history_diabetes <dbl>, hypertension_history <dbl>,
# cardiovascular_history <dbl>, bmi <dbl>, waist_to_hip_ratio <dbl>,
# systolic_bp <dbl>, diastolic_bp <dbl>, heart_rate <dbl>, ...
```

Pembahasan :

- Menghapus Nilai Hilang (NA) Langkah ini memastikan bahwa tidak ada observasi yang terhapus. Hal ini mengonfirmasi temuan di langkah EDA (3.d) bahwa dataset sangat bersih dan tidak mengandung nilai hilang (NA) eksplisit.
- Menghapus Duplikat Langkah ini mengonfirmasi temuan EDA (3.e) bahwa tidak ada baris yang merupakan duplikat sempurna. Setiap observasi dalam dataset adalah unik, menjamin bahwa model tidak akan mengalami bias yang disebabkan oleh entri data yang ganda.

Data Siap Digunakan Integritas Data Terjaga Dataset akhir mempertahankan ukuran penuhnya: 100.000 baris dan 31 kolom. Ini berarti proses pembersihan tidak mengakibatkan kehilangan data. Kualitas Data ini telah terverifikasi tidak memiliki masalah nilai hilang eksplisit maupun duplikat. Selain itu, berdasarkan ringkasan statistik (3.c), data ini juga bersih dari masalah umum "nilai 0 sebagai nilai hilang" pada metrik klinis.

D. KESIMPULAN

Kesimpulan dari semua praktikum yang sudah dikerjakan adalah saya berhasil mempraktikkan alur kerja standar dalam pengelolaan data menggunakan R di Google Colab. Awalnya, saya menggunakan data sederhana untuk mempelajari langkah-langkah dasar seperti membuat data frame, memeriksa struktur, dimensi, serta mendeteksi nilai hilang, duplikat, dan outlier. selanjutnya adalah menerapkan pengetahuan dasar ini pada dataset yang lebih besar dan realistik, yaitu dataset diabetes. Proses ini mengonfirmasi bahwa dataset tersebut memiliki kualitas yang sangat tinggi, tidak mengandung nilai hilang atau duplikat, yang merupakan hal langka dan sangat menguntungkan.